

DS d'info n°9

- 1) Select id from MEDICAL
where etat = 'hernie discale'
- 2) Select nom, prenom from PATIENT, MEDICAL
where patient.id = medical.id
and etat = 'spondylolisthésis'
- 3) Select etat, count(*) as nombre_de_patient from MEDICAL
group by etat.
- 4) Le type Array permet un accès plus facile et rapide
aux données du tableau et prends moins de place en mémoire.
- 5) Le tableau contient $N \times n$ valeurs, codées sur 32 bits
le vecteur contient N valeurs, codées sur 8 bits
Donc la mémoire nécessaire pour stocker le tableau et le :

$$100\,000 \times 6 \times 32 + 100\,000 \times 8 \text{ bits}$$

$$= 100\,000 \times 6 \times 4 + 100\,000 \text{ octets}$$

$$= 0,1 \times 6 \times 4 + 0,1 \text{ Mo}$$

$$= 2,1$$
- 6) def separationParGroupe (data, etat):

$$g_0, g_1, g_2 = [], [], []$$

$$n = \text{len}(\text{etat})$$

$$\text{for } i \text{ in range}(n):$$

```

if clst[i] = 0:
    g0.append(data[i,:])
if clst[i] = 1:
    g1.append(data[i,:])
if clst[i] = 2:
    g2.append(data[i,:])

return (g0, g1, g2)

```

7) ARGS 1 = $n, n, (xi + j + 1)$

ARGS 2 = $groupes[h, :, i], groupes[h, :, j],$
 $number = nb[h]$

ARGS 3 = $data[:, i]$

TEST = $i < j$

8) Les diagrammes de la diagonale permettent d'étudier la répartition de différents valeurs des attributs dans l'échantillon de patient.

Les diagrammes en dehors de la diagonale permettent d'observer la présence ou l'absence de corrélation entre deux attributs en fonction de l'état de santé.

9)
$$x_{norm j} = \frac{x_j - \min(X)}{\max(X) - \min(X)}$$


```

10) def min_max(x):
    min, max = x[0], x[0]
    n = len(x)
    for i in range(1, n):
        if x[i] < min:
            min = x[i]
        if x[i] > max:
            max = x[i]
    return (min, max)

```

```

11) def distance(z, data):
    n = len(z)
    l = len(data[:, 0])
    distances = []
    for i in range(l):
        s = 0
        for h in range(n):
            s += (data[i, h] - z[h])**2
        distances.append(s**0,5)
    return (distances)

```

12) La partie 1 crée la liste T, qui contient les couples
 (distance Z, ligne i ; i)
 et la trie en place ~~selon~~ par distance croissante.
 dist est la liste de distance entre Z et les lignes de data.
 La partie 2 crée la liste select, qui ~~contient~~ contient le
 nombre de patient pour chaque état, et la renvoie

~~On voit les états en~~ ~~présent~~ ~~le~~ en compte les états
des K patients les plus proches de z .

La troisième partie cherche ~~et renvoie~~ dans select
et renvoie l'état le plus représenté (parmi les K
patients les plus proches de z)

res est ~~la~~ le nombre de patients le plus de l'état
le plus représenté, et ind est cet état.

13) La somme des valeurs sur la diagonale de la matrice
est le nombre de bon diagnostics faits par l'IA.

En lisant la 1^{re} ligne, on voit que sur les 34 patients
en état 0, 23 ont été diagnostiqués en état 0 par l'IA,
4 en état 1 et 7 en état 2

En lisant la 1^{re} colonne, on voit que sur les 35 patients
que l'IA a diagnostiqué avec l'état 0, 23 avaient
effectivement l'état 0, 7 avaient l'état 1, et 5 l'état 2.

Cette matrice sert donc à voir si l'IA est juste,
~~et si deux états sont souvent~~
et si les mauvais diagnostics sont récurrents, ou plus fréquents
avec certains états.

14) On voit que l'incidence du nombre de voisins est de
5% ou plus, que le nombre optimal est environ 10
et que, pour cette valeur, l'algorithme fait environ
 $\frac{3}{4}$ de bons diagnostics.


```

15) def moyenne (sc):
    n = len(sc)
    s = 0
    for i in sc:
        s += i / n
    return (s)

```

```

def variance (sc):
    n = len(sc)
    v = 0
    mu = moyenne(sc)
    for i in sc:
        v += ((i - mu)**2) / n
    return (v)

```

```

16) def synthese (data, est):
    groupes = separationParGroupe (data, est)
    res = []
    n = len(data[0])
    for e in range(3):
        t = []
        for i in range(n):
            v = variance (groupes [e, :, i])
            mu = moyenne (groupes [e, :, i])
            t.append([mu, v])
        res.append(t)
    return (res)

```

from math import e as exp, pi

17) def gaussienne (a, moy, v):

return $\left(\exp \left(- \frac{(a - moy)^2}{2 \times v} \right) / (2 \times pi \times v) \right)$
 ** 0.5)

18) def probabilite Groupe (z, data, etot):

synt = synthese (data, etot)

groupes = separation par Groupe (data, etot)

n = len (data [0])

l = len (data[:, 0])

p = [(len (groupes [i, :, 0]) / l) for i in range (3)]

ans = []

for e in range (3):

 s = 0

 for h in range (n):

 mu, v = synt [e, h, 0], synt [e, h, 1]

 s = gaussienne (z [h], mu, v) * s

 ans.append (p [e] * s)

return (ans)

19) def prediction (Z, data, etot):

prob = probabilite Groupes (Z, data, etot)

c = 0

v = prob [0]

for i in range (1: 3):

 if prob [i] > v:

$$V = \text{prob.}[i]$$

$$C = i$$

return (c)

- 20) L'utilisation du logarithme permet de calculer la probabilité finale avec ~~des~~ ^{une} sommes plutôt qu'un produit, ce qui permet de réduire les erreurs de calcul dues aux arrondis, et de faciliter les expressions.