

Question 1:  
SELECT idpatient  
FROM MEDICAL  
WHERE etat = "hernie discale"

Question 2:  
SELECT nom, prenom  
FROM MEDICAL  
JOIN MEDICAL ON PATIENT.id = MEDICAL.idpatient  
WHERE etat = "spondylolisthesis"

Question 3:  
SELECT etat, COUNT(DISTINCT idpatient)  
FROM MEDICAL  
GROUP BY etat

Question 4: il est beaucoup plus rapide de parcourir avec un tableau avec numpy. Et en plus comme le montre l'annexe il existe plein de fonctions implémentées pour manier les tableaux de grande taille.

Ainsi Numpy est plus efficace pour traiter les tableaux de grande taille que les liste python.

Question 5: Le tableau data serait une matrice de  $N = 100\,000$  ligne et  $n = 6$  colonnes etc. Chaque case contient une donnée codée sur 32 bit soit 4 octet par case. Ainsi le tableau data utiliserait  $N \times n \times 4$  octet soit  $2\,400\,000$  octet = 2,4 Mo.

Le tableau etat serait un vecteur à  $N = 100\,000$  lignes chaque ligne contient une donnée codée sur 8 bit soit 1 octet de mémoire utilisé par ligne soit 1 Mo utilisé en tout.



Ainsi il faut 2,5 Mo de mémoire pour pouvoir stocker le tableau data et état.

Question 6:  

```
def separationParGroupe(data, état):  
    e = [[], [], []]  
    for i in range(len(etat)):  
        e[état[i]] = append(data[i])  
    return e
```

Question 9: 
$$x_{normij} = \frac{-x_{min}}{x_{max} - x_{min}}$$

Question 10:  

```
def min-max(X):  
    min = ...  
    max = X[0]  
    for i in X:  
        if i <= min:  
            min = i  
        if i >= max:  
            max = i  
    return min, max
```

Question 11:  

```
def distance(z, data):  
    e = []  
    for i in range(len(data)):  
        s = 0  
        for j in range(len(z)):  
            s = (data[i][j] - z[j])^2  
        dist = sqrt(s)  
        e = e.append(dist)  
    return e
```



Si on doit utiliser la technique de normalisation:

Question 11: def distance(z, data):

```
l = l3
for i in range(len(z)):
    l = l.append(min-max(data[:, i] + [z[i]]))
d = []
for i in range(len(data)):
    s = 0
    for j in range(len(z)):
        s = (((data[i][j] - l[j][0]) /
        (l[j][1] - l[j][0])) - ((z[j] - l[j][0]) / (l[j][1] - l[j][0]))
        )^2.
    dist = sqrt(s)
    d = d.append(dist)
return d.
```

Question 12: La partie 1 crée la liste T décrit dans le sujet et la trie.

La partie 2 crée une liste select de longueur nb où il place dans chaque case correspondant au nombre d'un état le nombre de voisin proche dans cet état.

Par exemple la donnée select[0] est le nombre de voisin proche qui ont un état normal dans notre exemple.

La partie 3 cherche le maximum de select et son indice qui correspond à l'état qui possèdent le plus de proche voisin. C'est ce qui renvoie.



Question 13:

La diagonale indique pour chaque état qui correspond au numéro des colonnes

Le nombre de fois où cet état a été l'état avec le plus de proche voisin une de data test.

et data.

Question 14: La courbe obtenue nous donne le pourcentage de réussite de l'algorithme KNN. Cela nous indique

quand utilisant l'algorithme KNN on a une 70% et 75% de chance de bien catégoriser un nouveau patient dans le bon état.