

DS d'info. n°3

1) `SELECT idpatient from MEDICAL where etat = 'hernie discale';`

2) `SELECT nom, prenom from PATIENT join MEDICAL  
on PATIENT.id = MEDICAL.idpatient where etat = 'spondylolisthésis';`

3) `SELECT etat, count(idpatient) from PATIENT group by etat;`

Distinct

4) Quand les tableaux sont de grande taille, la bibliothèque de calcul numérique Numpy permet d'aller plus vite.

5) Le tableau a  $N$  lignes et  $m$  colonnes.

Ici  $N = 100\,000$  et  $m = 6$ . Il y a donc  $600\,000$  cases.

Chaque case est codée sur  $32\text{ bits} = 4\text{ octets}$ .

On a donc  $4(600\,000) = 2\,400\,000$  octets

Il faut donc 2,4 Mo pour le tableau data.

6) def repartitionParGroupe(data, etat):

N = len(data)

O = []

X = []

E = []

for k in range(N):

if etat[k] = 0 :

O.append(data[k,:])

elif etat[k] = 1 :

X.append(data[k,:])

else :

E.append(data[k,:])

return [O, X, E]

7) ARGS1 = m, n, ~~i~~m = n + j

ARG S2 = groupes[i], groupes[j], marker = mark[m\*i + j]

ARG S3 = groupes[i]

TEST = i != j

Doit dépendre  
de k



8) Les diagrammes diagonaux permettent d'avoir un récapitulatif du nombre de patients en fonction des valeurs d'un attribut. Cela permet de voir où se situe la majorité des personnes. ✓

Les diagrammes non diagonaux permettent de regarder le lien entre deux attributs. Cela peut permettre d'exprimer la cause d'un attribut. ✓

9) 
$$x_{normij} = \frac{x_{ij} - \min(x)}{\max(x) - \min(x)}$$
 ✓

10) ~~def min\_max(x):~~  
    ~~return min(x), max(x)~~

Sans les fonctions min et max:  
def min\_max(x):

    n = len(x)

    max = x[0]

    min = x[0]

    for i in range(1, n):

        if x[i] > max:

            max = x[i]

        if x[i] < min:

            min = x[i]

    return min, max

OK

Complexité ?

11) def distance(z, data):

    min, max = min\_max(data[:, z])

    dz =

12) Partie 1: On crée une liste  $T$  avec la distance entre le  $n$ -uplet à classer et le connu et sa valeur d'état.

Puis on la trie par ordre croissant des distances. ✓

Partie 2: On crée une matrice ligne nulle de taille  $nb$ .  
On lui ajoute 1 et la valeur de état pour tous les entiers entre 0 et  $k-1$ . ✓

Partie 3: On cherche la plus grande valeur d'indice pour lequel sa valeur correspondante dans  $select$  pour l'indice est la plus grande. ✓

$T$ : liste avec la distance entre le  $n$ -uplet à classer et celle avec le  $n$ -uplet connu ainsi que sa valeur d'état.

$dist$ : les distances euclidiennes entre le  $n$ -uplet  $z$  et chaque  $n$ -uplet de data. ✓

$select$ : matrice ligne qui contient la valeur de état  $T[i][k]$ . ✓



plus 1.

ind: indice pour lequel la valeur avec cet indice dans  
select est la plus grande.



```

15) def moyenne(x):
    S=0
    for k in range(len(x)):
        S=S+x[k]
    return S/len(x)

```

```

def variance(x):
    S=0
    u=moyenne(x)
    for k in range(len(x)):
        S=S+x[k]-u**2
    return S/len(x)

```

```

16) def synthese(data, etat):
    L=[X0=[ ]=X1=X2]
    for k in range(6):
        for i in range(len(data)):
            if etat[i]==0:
                X0.append(data[i])

```

```

            if etat[i]==1:
                X1.append(data[i])
            elif:
                X2.append(data[i])

```

```

A=[moyenne(X0), variance(X0)]
B=[moyenne(X1), variance(X1)]
C=[moyenne(X2), variance(X2)]
X0=X1=X2=[ ]
L.append(A,B,C)
return L

```

```
17) import numpy as np
def gaussienne(a, moy, v):
    e = np.exp(-(a - moy)**2 / 2 / v)
    return e / (np.sqrt(2 * np.pi * v))
```

```
18) def probabiliteGroupe(z, data, etat):
    L = synthese(data, etat)
    P = 1
    Q = R
    for i in range(6):
        a, b = L[i, 0]
        P = gaussienne(data[i:], a, b) * P
        c, d = L[i, 1]
        Q = Q * gaussienne(data[i:], c, d)
        e, f = L[i, 2]
        R = R * gaussienne(data[i:], e, f)
    return [P, Q, R]
```



19) def prediction (z, data, etat):

$P_0, P_1, P_2 = \text{probabilite Groupe (z, data, etat)}$

if  $P_1 > P_0$ :

if  $P_2 > P_1$ :

return 2

else:

return 1

if  $P_2 > P_0$ :

return 2

else:

return 0

20) Les valeurs de probabilité trouvées sont très petites. L'ordinateur peut avoir du mal à les différencier. En prenant le logarithme décimal on se ramène à des valeurs que peut calculer l'ordinateur sans erreur. Par exemple,

$$P_0 = 1,1 \times 10^{-15} \quad \log P_0 \approx -15$$

$$P_1 = 7,4 \times 10^{-16} \quad \log P_1 \approx -16$$