



HOW TO WRITE GOOD CODE:



Architecture matérielle et initiation à l'algorithmique Informatique

Chapitre 1 – 08

Représentation des nombres

11 Décembre 2019

Savoirs et compétences :

- AA.C2 : Appréhender les limitations intrinsèques à la manipulation informatique des nombres
- AA.C3 : Initier un sens critique au sujet de la qualité et de la précision des résultats de calculs numériques sur ordinateur
- AA.S4 : Principe de la représentation des nombres entiers en mémoire
- AA.S5 : Principe de la représentation des nombres réels en mémoire

1	Base de numération	2
1.1	Rappel de CP : la base dix	2
1.2	Numération de position en base 10	2
1.3	Pourquoi dix ?	2
1.4	La base seize (hexadécimale)	2
1.5	Enfin : la base deux !	3
2	Représentation des entiers sur ordinateur	5
2.1	Cadre	5
2.2	Somme d'entiers naturels	5
2.3	Entiers relatifs	5
2.4	Dans les langages de programmation	6
3	Représentation des réels	6
3.1	Généralités	6
3.2	Virgule fixe	6
3.3	Virgule flottante	7
3.4	Virgule flottante en binaire	7
3.5	Norme IEEE 754	7
3.6	En Python	8
3.7	Problèmes de précision	8
3.8	Erreurs d'arrondis : conséquences	10
4	Annexe : représentation détaillé des entiers	10
5	Applications	15
5.1	Dochotomie	15

1 Base de numération

1.1 Rappel de CP : la base dix

Chiffre : symbole utilisé pour représenter certains entiers.

Les chiffres «usuels» : 0, 1, 2, 3, 4, 5, 6, 7, 8, 9.

Le nombre dix joue un rôle particulier.

- C'est le plus petit entier naturel non représentable uniquement par un chiffre.
- Pour compter des objets en grand nombre, on les regroupe par paquets de dix.

Exemple : Pour compter |||||, on obtient

||||| ||||| |||

Deux paquets (deux dizaines), reste quatre unités.

Quand il y a trop de dizaines, on regroupe les dizaines par paquets de dix (centaines), les centaines par paquets de dix (milliers), etc.

1.2 Numération de position en base 10

On décompose un entier en dizaines, centaines, milliers, etc. L'essentiel est alors qu'il y ait strictement moins de dix éléments dans chaque type de paquet. Ce nombre d'éléments peut être représenté par un chiffre. On écrit alors tous les chiffres à la suite. À gauche, on place les chiffres de poids fort (gros paquets). À droite, les chiffres de poids faible.

Ainsi 2735 représente deux milliers plus sept centaines plus trois dizaines plus cinq unités.

De manière générale, avec $B = 10$ et $n \in \mathbb{N}$,

$$\underline{a_n a_{n-1} \dots a_1 a_0}_B = \sum_{k=0}^n a_k B^k, \text{ et } \forall k \in \llbracket 0; n \rrbracket, a_k \in \llbracket 0; B \rrbracket.$$

1.3 Pourquoi dix ?

Pourquoi regrouper par dix pas plutôt par deux ? ou trois ? ou six ? ou huit ?

- Raison anthropomorphique (dix doigts) et poids de l'histoire.
- À peu près aucune raison mathématique.

On peut choisir une autre base.

- Deux : Amérique du Sud et Océanie.
- Cinq : Afrique, Romains et Maya (partiellement).
- Six : Papouasie Nouvelle-Guinée.
- Huit : certains dialectes amérindiens (Pame, Mexique ; Yuki, Californie), proposition de Charles XII de Suède.
- Douze : Népal, Europe.
- Vingt : Bhoutan, Aztèques, Maya, Gaulois (?), Basques (?).
- Soixante : Babyloniens, Indiens et Arabes (trigo)

(source : Wikipédia, article *Numération*)

À chaque fois, le principe est identique : on change juste B dans l'écriture précédente.

1.4 La base seize (hexadécimale)

On reprend le même principe que précédemment, avec $B = 16$ (on forme des paquets de 16 etc.). Mais cette fois on manque de chiffres pour représenter les nombres de zéro inclus à seize exclu (il en manque six).

On rajoute de nouveaux « chiffres » :

- a** dix
- b** onze
- c** douze
- d** treize
- e** quatorze
- f** quinze

On peut alors se mettre à compter en hexadécimal !

$0_{16} = 0$	$10_{16} = 16$	$20_{16} = 32$	$30_{16} = 48$	$100_{16} = 256$
$1_{16} = 1$	$11_{16} = 17$	$21_{16} = 33$	$40_{16} = 64$	$200_{16} = 512$
\vdots	\vdots	\vdots	\vdots	$1\ 000_{16} = 4096$
$9_{16} = 9$	$19_{16} = 25$	$29_{16} = 41$	$90_{16} = 144$	$10\ 000_{16} = 65536$
$a_{16} = 10$	$1a_{16} = 26$	$2a_{16} = 42$	$a0_{16} = 160$	
$b_{16} = 11$	$1b_{16} = 27$	$2b_{16} = 43$	$b0_{16} = 176$	
$c_{16} = 12$	$1c_{16} = 28$	$2c_{16} = 44$	$c0_{16} = 192$	
$d_{16} = 13$	$1d_{16} = 29$	$2d_{16} = 45$	$d0_{16} = 208$	
$e_{16} = 14$	$1e_{16} = 30$	$2e_{16} = 46$	$e0_{16} = 224$	
$f_{16} = 15$	$1f_{16} = 31$	$2f_{16} = 47$	$f0_{16} = 240$	

1.5 Enfin : la base deux !

C'est toujours le même principe, mais avec $B = 2$; on représente les nombres « par paquets de deux ». Pas de problème pour les chiffres, nous n'en avons besoin que de deux. Par convention : 0 et 1.

$0_2 = 0$	$10_2 = 2$	$100_2 = 4$	$1000_2 = 8$
$1_2 = 1$	$11_2 = 3$	$101_2 = 5$	$1\ 0000_2 = 16$
		$110_2 = 6$	$10\ 0000_2 = 32$
		$111_2 = 7$	$100\ 0000_2 = 64$
			$1000\ 0000_2 = 128$
			$1\ 0000\ 0000_2 = 256$

+	0	1
0	0	1
1	1	10

Table d'addition en binaire

*	0	1
0	0	0
1	0	1

Table de multiplication en binaire

1.5.1 Intérêts du binaire

Les nombres binaires sont facilement représentables par un dispositif mécanique/électrique/électronique/optique/électromagnétique etc. De plus, les tables d'opérations très simples et sont facilement calculables par un dispositif mécanique/électrique/électronique etc.

C'est le système utilisé pour représenter les nombres en interne dans un ordinateur.

1.5.2 Écriture d'un naturel p en binaire

Donnons d'abord un algorithme par divisions successives. Si $p = \underline{a_n \dots a_0}_2$, alors

$$p = \sum_{k=0}^n a_k 2^k = 2 \sum_{k=1}^n a_k 2^{k-1} + a_0.$$

Ainsi, a_0 est le reste de la division euclidienne de p par 2 et, si $p \neq a_0$, $\underline{a_n \dots a_1}_2$ est le quotient de la division euclidienne de p par 2.

On peut donc écrire la fonction suivante.

```
def conv_b2(p):
    """Convertit l'entier p en base 2 (renvoie une chaîne)"""
    x = p
    s = ""
    while x > 1 :
        s = str(x%2) + s
        x = x // 2
    return str(x)+s

print('0=' + conv_b2(0) + ' et 1=' + conv_b2(1) + ' et 42=' + conv_b2(42))
```

Cela renvoie alors :

$0=0$ et $1=1$ et $42=101010$

Voici une autre idée : calculer 2^k pour $k = 0, \dots$ jusqu'à avoir $2^k > p$. Alors, p s'écrit sur k bits et le bit de poids fort est 1. Le reste des bits est donné par la représentation en binaire de $p - 2^{k-1}$.

1.5.3 Calcul d'entier représenté en binaire

On veut calculer l'entier p , représenté par une suite de bits $a_n a_{n-1} \dots a_1 a_0$, i.e. $\sum_{k=0}^n a_k 2^k$.

On peut effectuer le calcul naïvement, en pensant bien à calculer les puissances de proche en proche.

```
def calc_b2_naif(s):
    """Renvoie l'entier p représente en binaire par s"""
    p = 0
    x = 1 ## 2**0
    for i in range(len(s)):
        p = p+int(s[len(s)-i-1])*x
        x = 2*x
    return p

print(0==calc_b2_naif("0"))
print(1==calc_b2_naif("1"))
print(42==calc_b2_naif("101010"))
```

Cela renvoie alors :

True
True
True

On peut faire mieux en mettant en œuvre l'algorithme de Horner. Il suffit de remarquer que

$$p = \sum_{k=0}^n a_k 2^k = a_0 + 2 \left(\sum_{k=1}^n a_k 2^{k-1} \right) = a_0 + 2(a_1 + 2(a_2 + 2(\dots + 2a_n)))$$

```
def calc_b2_horner(s):
    """Renvoie l'entier p représente en binaire par s"""
    p = int(s[0])
    for i in range(1, len(s)):
        p = int(s[i])+2*p
    return p

print(0==calc_b2_naif("0"))
print(1==calc_b2_naif("1"))
print(42==calc_b2_naif("101010"))
```

Cela renvoie alors :

True
True
True



1. S'ils sont bien mis en œuvre, ces algorithmes de conversion demandent un temps de calcul de l'ordre de n opérations pour un nombre de n chiffres (binaires ou décimaux), soit de l'ordre de $\log p$ opérations.
2. Il existe des algorithmes plus efficaces. Meilleure complexité connue : complexité d'une multiplication de nombres de n chiffres, soit $O(n \log n \log \log n)$ [Knuth].
3. Peu importe la base dans laquelle vous faites vos calculs, ces algorithmes permettent de convertir entre la base 2 et votre base habituelle.

2 Représentation des entiers sur ordinateur

2.1 Cadre

Sur un ordinateur récent :

- on travaille sur des mots-machine de 64 bits (8 octets) ;
- les opérations d'addition et de multiplication d'entiers internes au processeur se font sur 64 bits.

De manière générale, on s'intéressera au fonctionnement sur des ordinateurs travaillant sur des mots de n bits ($n \geq 2$), mais pour les exemples, on prendra systématiquement $n = 16$.

2.2 Somme d'entiers naturels

Sur un processeur n bits, un registre du processeur a n bits et peut représenter tout entier (naturel) de $\llbracket 0, 2^n \llbracket$.

Lorsqu'on effectue l'addition de deux registres r_1 et r_2 pour stocker le résultat dans r_3 , le registre fait n bits : s'il y a une retenue, elle est perdue.¹

■ **Exemple** Après addition de $\underline{1111\ 0000\ 1111\ 0000}_2$ et $\underline{0011\ 0011\ 0011\ 0011}_2$ sur 16 bits, le registre résultat contient : $\underline{0010\ 0100\ 0010\ 0011}_2$. ■

2.3 Entiers relatifs

On veut maintenant pouvoir travailler avec des entiers relatifs et notamment les additionner et les soustraire!

2.3.1 Avec signe et valeur absolue

Première possibilité de codage d'un entier relatif sur n bits : on utilise $n - 1$ bits pour la valeur absolue et 1 bit pour le signe.

■ **Exemple** Représentons les entiers relatifs sur 3 bits avec cette méthode :

- On utilise $3 - 1 = 2 \text{ bits}$ pour la valeur absolue et 1 bit pour le signe.
- On représente alors les entiers de -3 à $+3$ avec deux fois la représentation de 0.
- Avec cette représentation l'addition est compliquée à mettre en oeuvre et incohérente avec la méthode habituelle : $2 + (-1) = \underline{010}_2 + \underline{101}_2 = \underline{111}_2$.

Signe	Valeur absolue	Représentation binaire	Représentation décimale
0	00	$\underline{000}_2$	+0
0	01	$\underline{001}_2$	+1
0	10	$\underline{010}_2$	+2
0	11	$\underline{011}_2$	+3
1	00	$\underline{100}_2$	-0
1	01	$\underline{101}_2$	-1
1	10	$\underline{110}_2$	-2
1	11	$\underline{111}_2$	-3

Ainsi, cette représentation n'est quasiment jamais utilisée pour les nombres entiers d'un processeur.

2.3.2 Complément à deux

On va utiliser l'idée suivante. Remarquons que l'addition d'entiers naturels sur le processeur n'est pas correcte mais l'est modulo 2^n . De plus, pour tout $p \in \mathbb{Z}$, $p \% 2^n \in \llbracket 0, 2^n \llbracket$. Ainsi, $p \% 2^n$ est représentable sur n bits.

C'est donc la représentation en complément à deux qui est le plus souvent utilisée : un entier relatif p est représenté sur n bits comme l'entier naturel $p \% 2^n$.

Ainsi sur n bits on représentera tous les entiers relatifs compris dans l'intervalle $\llbracket -2^{n-1}, 2^{n-1} \llbracket$

Ⓡ L'addition d'entiers relatifs (on dit aussi signés) sera correcte modulo 2^n et utilisera les mêmes circuits que l'addition d'entiers naturels.

■ **Exemple**

1. En fait une trace en est généralement gardée dans un autre registre du processeur.

sur 3 bits :

- 2 est codé par $2\%2^3 = 2 = \underline{001}_2$;
- -2 est codé par $-2\%2^3 = 6 = \underline{110}_2$ car $-2 = -1 \times 2^3 + 6$

Avec cette représentation l'addition est cohérente : $2 + (-1) = \underline{010}_2 + \underline{111}_2 = \underline{001}_2 = 1$.
On trouve donc la table ci-contre :

Entier relatif en décimal	entier relatif en binaire
-4	$\underline{100}_2$
-3	$\underline{101}_2$
-2	$\underline{110}_2$
-1	$\underline{111}_2$
0	$\underline{000}_2$
1	$\underline{001}_2$
2	$\underline{010}_2$
3	$\underline{011}_2$

2.3.3 Soustraction d'entiers relatifs

Elle peut se faire relativement facilement (voir annexe).

2.4 Dans les langages de programmation

Dans de nombreux langages (C, Java, ...) :

Entiers du langage = Entiers sur n bits

Dans ces langages, sur une machine 64 bits, $4 * 2^{62}$ vaut 0.

Dans d'autres langages, les entiers ne sont pas les entiers machines. Plusieurs représentations sont possibles. Parmi celles classiques : on utilise un tableau dont les éléments sont des octets/mots machines/chiffres dans une base B (avec B puissance de 2 ou 10). Des fonctions internes au langage prennent alors soin d'effectuer les opérations correctement (en utilisant le fait que le processeur sait calculer sur n bits). Python est dans ce cas.

3 Représentation des réels

L'essentiel à savoir :

- Le principe de la représentation des nombres normalisés.
- Les origines des problèmes de précision.
- Les conséquences de ces problèmes.

3.1 Généralités

Mathématiquement, il y a de nombreuses façons de voir les réels.

Une façon particulière : c'est la donnée d'un entier relatif, donnant la partie entière, et d'une suite (infinie) de chiffres, donnant la partie fractionnaire.

Peut-on représenter une suite de chiffres infinies ? Oui, par un algorithme.

Peut-on représenter toutes les suites de chiffres infinies ? Non (cela découle des travaux de Cantor et de Turing).

Pour des besoins de calcul scientifique, nous n'avons pas besoin de représenter tous les réels. On travaille avec des approximations des réels : ici, les nombres décimaux.

R Qui dit approximation dit erreur.

Définition Soit $(a, x) \in \mathbb{R}^2$. On distingue deux notions d'erreurs dans l'approximation de x par a .

Erreur absolue : $|x - a|$

Erreur relative : $\frac{|x - a|}{|x|}$ (non définie si $x = 0$)

On a aussi besoin d'avoir une représentation des nombres de taille réduite :

- pour prendre une place réduite (en mémoire, sur disque, sur le réseau) ;
- pour calculer vite.

3.2 Virgule fixe

On représente tous les nombres décimaux avec un nombre n fixé de chiffres après la virgule.

Avantage : on comprend bien comment ça marche.

Inconvénient :

- On a parfois besoin de beaucoup de chiffres après la virgule (masse de l'électron : 9×10^{-31} kg, $h \approx 6 \times 10^{-34}$ J.s).
- Garder 30 chiffres après la virgule est parfois inutile pour manipuler un grand nombre (durée de vie moyenne de l'électron : 10^{34} s).

Dans cette représentation, l'erreur absolue est au plus 10^{-n} . Mais l'important est souvent l'erreur relative.

3.3 Virgule flottante

On utilise plutôt l'idée de la notation scientifique des nombres. Un nombre est représenté sous la forme $s \times m \times 10^e$, avec (s, m, e) définis comme suit.

- $s \in \{-1; +1\}$ est le signe.
- $m \in [1, 10[$ est un nombre décimal, avec n chiffres après la virgule (n fixé). C'est la mantisse.
- e : entier (relatif) appartenant à une plage de valeurs fixée. C'est l'exposant.

■ **Exemple** Sur une calculatrice HP48SX (d'après tests personnels) :

- la mantisse m a 11 chiffres après la virgule,
- l'exposant $e \in \llbracket -499, 500 \rrbracket$.

Cela permet de représenter :

- de très grands nombres : jusqu'à $9,999\,999\,999\,99 \times 10^{499}$;
- de très petits (en valeur absolue) : jusqu'à 10^{-499} ;
- et leurs opposés : $-9,999\,999\,999\,99 \times 10^{499}$ et -10^{-499} ;
- avec une erreur relative inférieure à 10^{-11} .

avec seulement 12 chiffres décimaux, un signe et trois chiffres pour l'exposant. ■

3.4 Virgule flottante en binaire

La notation scientifique présentée plus haut utilise la base 10. C'est souvent cohérent, mais pas toujours en informatique où l'on préférera utiliser la base 2. On a alors l'équivalent de la notion de nombre décimal, dans la base 2.

Définition Un nombre (ou fraction) décimal est un nombre de la forme $\frac{n}{10^k}$, avec $n \in \mathbb{Z}$ et $k \in \mathbb{N}$.

Définition Un nombre (ou fraction) dyadique est un nombre de la forme $\frac{n}{2^k}$, avec $n \in \mathbb{Z}$ et $k \in \mathbb{N}$.

■ **Exemple** En décimal le nombre $12345/10^3$ s'écrit 12,345. ■

■ **Exemple** En binaire, le nombre $\frac{10101011_2}{10_2^{101_2}}$ s'écrit $101,01011_2$. Il vaut $\frac{171}{2^5} = 5,34375$.

Autre façon de calculer :

$$101,01011_2 = 2^2 + 0 \times 2^1 + 2^0 + \frac{0}{2} + \frac{1}{2^2} + \frac{0}{2^3} + \frac{1}{2^4} + \frac{1}{2^5} = 5 + \frac{1}{2^2} + \frac{1}{2^4} + \frac{1}{2^5}$$

Un nombre sera donc représenté en virgule flottante en base 2 sous la forme $s \times m \times 2^e$, avec (s, m, e) comme suit.

- $s \in \{-1; +1\}$ est le signe.
- $m \in [1, 2[$ est un nombre dyadique, avec n chiffres après la virgule (n fixé). C'est la mantisse.
- e : entier (relatif) appartenant à une plage de valeurs fixée. C'est l'exposant.

On commet au plus une erreur relative de 2^{-n} en représentant un réel ainsi. ■

3.5 Norme IEEE 754

La norme IEEE 754 est utilisée dans tous les ordinateurs pour les nombres à virgule flottante. Elle existe en plusieurs versions (simple précision, double précision, double précision étendue). On ne parlera ici que de la double précision (la plus répandue).

Les nombres réels seront donc représentés en virgule flottante avec double précision. Chaque nombre est représenté sur 64 bits, utilisés comme suit.

- 1 bit pour le signe (0 pour +, 1 pour -).
- 11 bits pour l'exposant décalé e (exposant plus 1023).
- 52 bits pour les 52 chiffres après la virgule de la mantisse (inutile de garder le premier bit de m : c'est 1).

On interprète donc la suite de bits $s e_{10} \dots e_0 m_1 \dots m_{52}$ comme le nombre x défini comme suit.

$$\text{Notons } e = \underline{e_{10} \dots e_0} = \sum_{k=0}^{10} e_k 2^k.$$

- Si $e \in \llbracket 1, 2047 \rrbracket$, x est le nombre normalisé :

$$x = s \times \underline{1, m_1 \dots m_{52}} \times 2^{(-1023 + e_{10} \dots e_0)} = s \times \left(1 + \sum_{k=1}^{52} \frac{m_k}{2^k} \right) \times 2^{(-1023 + \sum_{k=0}^{10} e_k 2^k)}$$

- Si $e = 0$ et $m_1 = \dots = m_{52} = 0$: $x = 0$ (deux versions : $+0$ et -0).
- Si $e = 0$ et m_1, \dots, m_{52} non tous nuls, x est le nombre dénormalisé :

$$x = s \times \underline{0, m_1 \dots m_{52}} \times 2^{-1022} = s \times \left(\sum_{k=1}^{52} \frac{m_k}{2^k} \right) \times 2^{-1022}$$

- Si $e = 2047$ et $m_1 = \dots = m_{52} = 0$: $x = s\infty$ ($+\infty$ ou $-\infty$).
- Si $e = 2047$ et m_1, \dots, m_{52} non tous nuls : $x = NaN$.

R On ne rentrera pas dans le détail des signification de $+\infty$, $-\infty$ et de NaN .

Les nombres normalisés permettent de représenter de façon précise les réels de $[-M, -m] \cup [m, M]$ avec

$$m \approx 2^{-1022} \approx 2 \times 10^{-308}$$

$$\text{et } M \approx 2^{1024} \approx 1,8 \times 10^{308}$$

Les nombres dénormalisés ne respectent pas la convention de la notation scientifique standard, mais permettent de représenter des nombres plus petits que les nombres normalisés ne peuvent.

3.6 En Python

Avec Python, on peut accéder à la représentation d'un nombre flottant par la méthode `.hex()`. Attention, le nombre est écrit en hexadécimal.

■ **Exemple** Avec `5.5`.

```
>>> 5.5.hex()
'0x1.6000000000000p+2'
```

En effet, on a

$$5,5 = \frac{11}{8} \times 4 = \left(1 + \frac{1}{4} + \frac{1}{8} \right) \times 2^2.$$

En binaire, on écrit $1,375 = 1 + \frac{1}{4} + \frac{1}{8}$ comme

$$1, \underbrace{0110}_{\frac{1}{4}} \underbrace{0000}_{\frac{1}{8}} \underbrace{0000}_{\frac{1}{16}} \underbrace{0000}_{\frac{1}{32}} \underbrace{0000}_{\frac{1}{64}} \underbrace{0000}_{\frac{1}{128}} \underbrace{0000}_{\frac{1}{256}} \underbrace{0000}_{\frac{1}{512}} \underbrace{0000}_{\frac{1}{1024}} \underbrace{0000}_{\frac{1}{2048}} \underbrace{0000}_{\frac{1}{4096}} \underbrace{0000}_{\frac{1}{8192}} \underbrace{0000}_{\frac{1}{16384}} \underbrace{0000}_{\frac{1}{32768}} \underbrace{0000}_{\frac{1}{65536}} \underbrace{0000}_{\frac{1}{131072}} \underbrace{0000}_{\frac{1}{262144}} \underbrace{0000}_{\frac{1}{524288}} \underbrace{0000}_{\frac{1}{1048576}} \underbrace{0000}_{\frac{1}{2097152}} \underbrace{0000}_{\frac{1}{4194304}} \underbrace{0000}_{\frac{1}{8388608}} \underbrace{0000}_{\frac{1}{16777216}} \underbrace{0000}_{\frac{1}{33554432}} \underbrace{0000}_{\frac{1}{67108864}} \underbrace{0000}_{\frac{1}{134217728}} \underbrace{0000}_{\frac{1}{268435456}} \underbrace{0000}_{\frac{1}{536870912}} \underbrace{0000}_{\frac{1}{1073741824}} \underbrace{0000}_{\frac{1}{2147483648}} \underbrace{0000}_{\frac{1}{4294967296}} \underbrace{0000}_{\frac{1}{8589934592}} \underbrace{0000}_{\frac{1}{17179869184}} \underbrace{0000}_{\frac{1}{34359738368}} \underbrace{0000}_{\frac{1}{68719476736}} \underbrace{0000}_{\frac{1}{137438953472}} \underbrace{0000}_{\frac{1}{274877906944}} \underbrace{0000}_{\frac{1}{549755813888}} \underbrace{0000}_{\frac{1}{1099511627776}} \underbrace{0000}_{\frac{1}{2199023255552}} \underbrace{0000}_{\frac{1}{4398046511104}} \underbrace{0000}_{\frac{1}{8796093022208}} \underbrace{0000}_{\frac{1}{17592186044416}} \underbrace{0000}_{\frac{1}{35184372088832}} \underbrace{0000}_{\frac{1}{70368744177664}} \underbrace{0000}_{\frac{1}{140737488355328}} \underbrace{0000}_{\frac{1}{281474976710656}} \underbrace{0000}_{\frac{1}{562949953421312}} \underbrace{0000}_{\frac{1}{1125899906842624}} \underbrace{0000}_{\frac{1}{2251799813685248}} \underbrace{0000}_{\frac{1}{4503599627370496}} \underbrace{0000}_{\frac{1}{9007199254740992}} \underbrace{0000}_{\frac{1}{18014398509481984}} \underbrace{0000}_{\frac{1}{36028797018963968}} \underbrace{0000}_{\frac{1}{72057594037927936}} \underbrace{0000}_{\frac{1}{144115188075855872}} \underbrace{0000}_{\frac{1}{288230376151711744}} \underbrace{0000}_{\frac{1}{576460752303423488}} \underbrace{0000}_{\frac{1}{1152921504606846976}} \underbrace{0000}_{\frac{1}{2305843009213693952}} \underbrace{0000}_{\frac{1}{4611686018427387904}} \underbrace{0000}_{\frac{1}{9223372036854775808}} \underbrace{0000}_{\frac{1}{18446744073709551616}} \underbrace{0000}_{\frac{1}{36893488147419103232}} \underbrace{0000}_{\frac{1}{73786976294838206464}} \underbrace{0000}_{\frac{1}{147573952589676412928}} \underbrace{0000}_{\frac{1}{295147905179352825856}} \underbrace{0000}_{\frac{1}{590295810358705651712}} \underbrace{0000}_{\frac{1}{1180591620717411303424}} \underbrace{0000}_{\frac{1}{2361183241434822606848}} \underbrace{0000}_{\frac{1}{4722366482869645213696}} \underbrace{0000}_{\frac{1}{9444732965739290427392}} \underbrace{0000}_{\frac{1}{18889465931478580854784}} \underbrace{0000}_{\frac{1}{37778931862957161709568}} \underbrace{0000}_{\frac{1}{75557863725914323419136}} \underbrace{0000}_{\frac{1}{151115727451828646838272}} \underbrace{0000}_{\frac{1}{302231454903657293676544}} \underbrace{0000}_{\frac{1}{604462909807314587353088}} \underbrace{0000}_{\frac{1}{1208925819614629174706176}} \underbrace{0000}_{\frac{1}{2417851639229258349412352}} \underbrace{0000}_{\frac{1}{4835703278458516698824704}} \underbrace{0000}_{\frac{1}{9671406556917033397649408}} \underbrace{0000}_{\frac{1}{19342813113834066795298816}} \underbrace{0000}_{\frac{1}{38685626227668133590597632}} \underbrace{0000}_{\frac{1}{77371252455336267181195264}} \underbrace{0000}_{\frac{1}{154742504910672534362390528}} \underbrace{0000}_{\frac{1}{309485009821345068724781056}} \underbrace{0000}_{\frac{1}{618970019642690137449562112}} \underbrace{0000}_{\frac{1}{1237940039285380274899124224}} \underbrace{0000}_{\frac{1}{2475880078570760549798248448}} \underbrace{0000}_{\frac{1}{4951760157141521099596496896}} \underbrace{0000}_{\frac{1}{9903520314283042199192993792}} \underbrace{0000}_{\frac{1}{19807040628566084398385987584}} \underbrace{0000}_{\frac{1}{39614081257132168796771975168}} \underbrace{0000}_{\frac{1}{79228162514264337593543950336}} \underbrace{0000}_{\frac{1}{158456325028528675187087900672}} \underbrace{0000}_{\frac{1}{316912650057057350374175801344}} \underbrace{0000}_{\frac{1}{633825300114114700748351602688}} \underbrace{0000}_{\frac{1}{1267650600228229401496703205376}} \underbrace{0000}_{\frac{1}{2535301200456458802993406410752}} \underbrace{0000}_{\frac{1}{5070602400912917605986812821504}} \underbrace{0000}_{\frac{1}{10141204801825835211973625643008}} \underbrace{0000}_{\frac{1}{20282409603651670423947251286016}} \underbrace{0000}_{\frac{1}{40564819207303340847894502572032}} \underbrace{0000}_{\frac{1}{81129638414606681695789005144064}} \underbrace{0000}_{\frac{1}{162259276829213363391578010288128}} \underbrace{0000}_{\frac{1}{324518553658426726783156020576256}} \underbrace{0000}_{\frac{1}{649037107316853453566312041152512}} \underbrace{0000}_{\frac{1}{1298074214633706907132624082305024}} \underbrace{0000}_{\frac{1}{2596148429267413814265248164610048}} \underbrace{0000}_{\frac{1}{5192296858534827628530496329220096}} \underbrace{0000}_{\frac{1}{10384593717069655257060992658440192}} \underbrace{0000}_{\frac{1}{20769187434139310514121985316880384}} \underbrace{0000}_{\frac{1}{41538374868278621028243970633760768}} \underbrace{0000}_{\frac{1}{83076749736557242056487941267521536}} \underbrace{0000}_{\frac{1}{166153499473114484112975882535043072}} \underbrace{0000}_{\frac{1}{332306998946228968225951765070086144}} \underbrace{0000}_{\frac{1}{664613997892457936451903530140172288}} \underbrace{0000}_{\frac{1}{1329227995784915872903807060280344576}} \underbrace{0000}_{\frac{1}{2658455991569831745807614120560689152}} \underbrace{0000}_{\frac{1}{5316911983139663491615228241121378304}} \underbrace{0000}_{\frac{1}{10633823966279326983230456482242756608}} \underbrace{0000}_{\frac{1}{21267647932558653966460912964485513216}} \underbrace{0000}_{\frac{1}{42535295865117307932921825928971026432}} \underbrace{0000}_{\frac{1}{85070591730234615865843651857942052864}} \underbrace{0000}_{\frac{1}{170141183460469231731687303715884105728}} \underbrace{0000}_{\frac{1}{340282366920938463463374607431768211456}} \underbrace{0000}_{\frac{1}{680564733841876926926749214863536422912}} \underbrace{0000}_{\frac{1}{1361129467683753853853498429727072845824}} \underbrace{0000}_{\frac{1}{2722258935367507707706996859454145691648}} \underbrace{0000}_{\frac{1}{5444517870735015415413993718908291383296}} \underbrace{0000}_{\frac{1}{10889035741470030830827987437816582766592}} \underbrace{0000}_{\frac{1}{21778071482940061661655974875633165533184}} \underbrace{0000}_{\frac{1}{43556142965880123323311949751266331066368}} \underbrace{0000}_{\frac{1}{87112285931760246646623899502532662132736}} \underbrace{0000}_{\frac{1}{174224571863520493293247799005065324265472}} \underbrace{0000}_{\frac{1}{348449143727040986586495598010130648530944}} \underbrace{0000}_{\frac{1}{696898287454081973172991196020261297061888}} \underbrace{0000}_{\frac{1}{1393796574908163946345982392040522594123776}} \underbrace{0000}_{\frac{1}{2787593149816327892691964784081045188247552}} \underbrace{0000}_{\frac{1}{5575186299632655785383929568162090376495104}} \underbrace{0000}_{\frac{1}{11150372599265311570767859136324180752990208}} \underbrace{0000}_{\frac{1}{22300745198530623141535718272648361505980416}} \underbrace{0000}_{\frac{1}{44601490397061246283071436545296723011960832}} \underbrace{0000}_{\frac{1}{89202980794122492566142873090593446023921664}} \underbrace{0000}_{\frac{1}{178405961588244985132285746181186892047843328}} \underbrace{0000}_{\frac{1}{356811923176489970264571492362373784095686656}} \underbrace{0000}_{\frac{1}{713623846352979940529142984724747568191373312}} \underbrace{0000}_{\frac{1}{1427247692705959881058285969449495136382746624}} \underbrace{0000}_{\frac{1}{2854495385411919762116571938898990272765493248}} \underbrace{0000}_{\frac{1}{5708990770823839524233143877797980545530986496}} \underbrace{0000}_{\frac{1}{11417981541647679048466287755595961091061972992}} \underbrace{0000}_{\frac{1}{22835963083295358096932575511191922182123945984}} \underbrace{0000}_{\frac{1}{45671926166590716193865151022383844364247891968}} \underbrace{0000}_{\frac{1}{91343852333181432387730302044767688728495783936}} \underbrace{0000}_{\frac{1}{182687704666362864775460604089535377456991567872}} \underbrace{0000}_{\frac{1}{365375409332725729550921208179070754913983135744}} \underbrace{0000}_{\frac{1}{730750818665451459101842416358141509827966271488}} \underbrace{0000}_{\frac{1}{1461501637330902918203684832716283019655932542976}} \underbrace{0000}_{\frac{1}{2923003274661805836407369665432566039311865085952}} \underbrace{0000}_{\frac{1}{5846006549323611672814739330865132078623730171904}} \underbrace{0000}_{\frac{1}{11692013098647223345629478661730264157247460343808}} \underbrace{0000}_{\frac{1}{23384026197294446691258957323460528314494920687616}} \underbrace{0000}_{\frac{1}{46768052394588893382517914646921056628989841375232}} \underbrace{0000}_{\frac{1}{93536104789177786765035829293842113257979682750464}} \underbrace{0000}_{\frac{1}{187072209578355573530071658587684226515959365500928}} \underbrace{0000}_{\frac{1}{374144419156711147060143317175368453031918731001856}} \underbrace{0000}_{\frac{1}{748288838313422294120286634350736906063837462003712}} \underbrace{0000}_{\frac{1}{1496577676626844588240573268701473812127674924007424}} \underbrace{0000}_{\frac{1}{2993155353253689176481146537402947624255349848014848}} \underbrace{0000}_{\frac{1}{5986310706507378352962293074805895248510699696029696}} \underbrace{0000}_{\frac{1}{11972621413014756705924586149611790497021399392059392}} \underbrace{0000}_{\frac{1}{23945242826029513411849172299223580994042798784118784}} \underbrace{0000}_{\frac{1}{47890485652059026823698344598447161988085597568237568}} \underbrace{0000}_{\frac{1}{95780971304118053647396689196894323976171195136475136}} \underbrace{0000}_{\frac{1}{191561942608236107294793378393788647952342390272950272}} \underbrace{0000}_{\frac{1}{383123885216472214589586756787577295904684780545900544}} \underbrace{0000}_{\frac{1}{766247770432944429179173513575154591809369561091801088}} \underbrace{0000}_{\frac{1}{1532495540865888858358347027150309183618739122183602176}} \underbrace{0000}_{\frac{1}{3064991081731777716716694054300618367237478244367204352}} \underbrace{0000}_{\frac{1}{6129982163463555433433388108601236734474956488734408704}} \underbrace{0000}_{\frac{1}{12259964326927110866866776217202473468949912977468817408}} \underbrace{0000}_{\frac{1}{24519928653854221733733552434404946937899825954937634816}} \underbrace{0000}_{\frac{1}{49039857307708443467467104868809893875799651909875269632}} \underbrace{0000}_{\frac{1}{98079714615416886934934209737619787751599303819750539264}} \underbrace{0000}_{\frac{1}{196159429230833773869868419475239575503198607639501078528}} \underbrace{0000}_{\frac{1}{392318858461667547739736838950479151006397215279002157056}} \underbrace{0000}_{\frac{1}{784637716923335095479473677900958302012794430558004314112}} \underbrace{0000}_{\frac{1}{1569275433846670190958947355801916604025588861116008628224}} \underbrace{0000}_{\frac{1}{3138550867693340381917894711603833208051177722232017256448}} \underbrace{0000}_{\frac{1}{6277101735386680763835789423207666416102355444464034512896}} \underbrace{0000}_{\frac{1}{12554203470773361527671578846415332832204710888928069025792}} \underbrace{0000}_{\frac{1}{25108406941546723055343157692830665664409421777856138051584}} \underbrace{0000}_{\frac{1}{50216813883093446110686315385661331328818843555712276103168}} \underbrace{0000}_{\frac{1}{100433627766186892221372630771322662657637687111424552206336}} \underbrace{0000}_{\frac{1}{200867255532373784442745261542645325315275374222849104412672}} \underbrace{0000}_{\frac{1}{401734511064747568885490523085290650630550748445698208825344}} \underbrace{0000}_{\frac{1}{803469022129495137770981046170581301261101496891396417650688}} \underbrace{0000}_{\frac{1}{1606938044258990275541962092341162602522202993782792835301376}} \underbrace{0000}_{\frac{1}{3213876088517980551083924184682325205044405987565585670602752}} \underbrace{0000}_{\frac{1}{6427752177035961102167848369364650410088811975131171341205504}} \underbrace{0000}_{\frac{1}{12855504354071922204335696738729300820177623950262342682411008}} \underbrace{0000}_{\frac{1}{25711008708143844408671393477458601640355247900524685364822016}} \underbrace{0000}_{\frac{1}{51422017416287688817342786954917203280710495801049370729644032}} \underbrace{0000}_{\frac{1}{102844034832575377634685573909834406561420991602098741459288064}} \underbrace{0000}_{\frac{1}{205688069665150755269371147819668813122841983204197482918576128}} \underbrace{0000}_{\frac{1}{411376139330301510538742295639337626245683966408394965837152256}} \underbrace{0000}_{\frac{1}{822752278660603021077484591278675252491367932816789931674304512}} \underbrace{0000}_{\frac{1}{1645504557321206042154969182557350504982735865633579863348609024}} \underbrace{0000}_{\frac{1}{3291009114642412084309938365114701009965471731267159726697218048}} \underbrace{0000}_{\frac{1}{6582018229284824168619876730229402019930943462534319453394436096}} \underbrace{0000}_{\frac{1}{13164036458569648337239753460458804039861886925068638906788872192}} \underbrace{0000}_{\frac{1}{26328072917139296674479506920917608079723773850137277813577744384}} \underbrace{0000}_{\frac{1}{52656145834278593348959013841835216159447547700274555627155488768}} \underbrace{0000}_{\frac{1}{105312291668557186697918027683670432318895095400549111254310977536}} \underbrace{0000}_{\frac{1}{210624583337114373395836055367340864637790190801098222508621955072}} \underbrace{0000}_{\frac{1}{421249166674228746791672110734681729275580381602196445017243910144}} \underbrace{0000}_{\frac{1}{842498333348457493583344221469363458551160763204392890034487820288}} \underbrace{0000}_{\frac{1}{1684996666696914987166688442938726917102321526408785780068975640576}} \underbrace{0000}_{\frac{1}{3369993333393829974333376885877453834204643052817571560137951281152}} \underbrace{0000}_{\frac{1}{673998666$$

■ **Exemple** Pour l'addition : $1,23 \times 10^3 + 4,56 \times 10^0 = 1,23456 \times 10^3$

Pour garder deux chiffres après la virgule, on arrondit le résultat et l'on introduit donc une erreur d'approximation. Ce problème se pose en décimal, comme en binaire!

3.7.2 Problèmes liés au passage à la représentation binaire

Attention : Les représentations binaires et décimales partagent les mêmes problèmes d'arrondis. Cependant, on crée des erreurs d'arrondis lors du passage d'une représentation à l'autre.

■ **Exemple** En Python, on rentrera dans la console des nombres en écriture décimale mais le calcul interne se fera en binaire. Cela donne la chose suivante.

```
>>> 0.1+0.2 == 0.3
False
>>> 0.1+0.2
0.30000000000000004
>>> 0.1+0.2-0.3
5.551115123125783e-17
```

Que se passe-t-il???

3.7.3 Origine de ce problème

Théorème Soit p/q un nombre rationnel écrit sous forme irréductible, c'est-à-dire avec p et q entiers, premiers entre eux et $q > 0$. Alors :

1. p/q est un nombre décimal si et seulement si q est de la forme $2^\alpha 5^\beta$ où $(\alpha, \beta) \in \mathbb{N} \times \mathbb{N}$;
 2. p/q est un nombre dyadique si et seulement si q est de la forme 2^α où $\alpha \in \mathbb{N}$.
- Ainsi, $\frac{1}{10}$ n'est pas un nombre dyadique. En écriture décimale,

$$1/10 = 0,1$$

alors qu'en écriture binaire,

$$1/10 = 0,00011001100110011001100110011\dots_2$$

Le flottant² (arrondi par défaut) x représentant $\frac{1}{10}$ est donc

$$1,10011001100110011001100110011001100110011001100110011001_2 \times 2^{-4}.$$

L'approximation dyadique au plus près de $0,1$ vaut donc

$$1,100110011001100110011001100110011001100110011010_2 \times 2^{-4},$$

qui est la représentation exacte de

0,10000000000000000055511151231257827021181583404541015625

De même, le flottant y (arrondi au plus proche) représentant $\frac{2}{10}$ est

$$\underline{1,100110011001100110011001100110011001100110011010}_2 \times 2^{-3}.$$

Ainsi, si on effectue le calcul de $x + y$, on obtient :

$$\begin{aligned} & \underline{0_2, 1100110011001100110011001100110011010_2} \cdot 2^{-3} \\ + & \underline{1_2, 1001100110011001100110011001100110011010_2} \cdot 2^{-3} \\ = & \underline{10_2, 0110011001100110011001100110011001100110110_2} \cdot 2^{-3} \end{aligned}$$

Arrondi au flottant le plus proche, cela donne :

$$\underline{1,00110011001100110011001100110011001100110100,2^{-2}},$$

soit

0,300000000000000000444089209850062616169452667236328125.

Cela explique bien ce que donne Python.

2. On comprendra : représentation normalisée à virgule flottante en double précision.

```
>>> 0.1+0.2
0.30000000000000004
```

Quand on effectue le calcul $0.1 + 0.2 - 0.3$, on crée de nouvelles erreurs d'arrondi. Ces dernières sont «négligeables» devant 0,1, mais pas négligeable 4×10^{-17} ! D'où le résultat final de l'ordre de 6×10^{-17} :

```
>>> 0.1+0.2-0.3
5.551115123125783e-17
```

3.8 Erreurs d'arrondis : conséquences

UN TEST DE LA FORME $x == 0$ ou $x == y$ POUR DES FLOTTANTS N'A AUCUN SENS!

La seule possibilité parfois raisonnable est le « test de petitesse ».

■ **Exemple** On peut tester $\text{abs}(x) < \text{epsilon}$ avec $\text{epsilon} = 1\text{e-}6$. ■

La question qui se pose alors est : quelle valeur de epsilon choisir? Il n'y a pas de réponse universelle, cela dépend du problème étudié...

De même, on se méfiera des tests du type $x < y$ ou $x \leq y$.

■ **Exemple** ■

Construisons une équation du second degré.

```
>>> r1 = 1 + 1.2e-16
>>> r1
1.0000000000000002
>>> r2 = 1
>>> a, b, c = 1, -(r1+r2), r1 * r2
```

Normalement $r1$ et $r2$ sont les deux racines réelles distinctes de $aX^2 + bX + c$, qui a donc un discriminant strictement positif. Vérifions cela.

```
>>> Delta = b**2 - 4*a*c
>>> Delta
-8.881784197001252e-16
```

Oups...

```
>>> a*r1**2 + b*r1 + c
2.220446049250313e-16
>>> a*r2**2 + b*r2 + c
2.220446049250313e-16
```

On peut aussi trouver des cas où Delta est nul avec le polynôme qui s'annule au moins sur deux flottants, dont l'un n'est pas supposé être une racine...

4 Annexe : représentation détaillé des entiers

Conversion d'un entier en base 2

On s'intéresse à la démonstration de l'algorithme de conversion par divisions successives. Si $p = \underline{a_n \dots a_0}_2$, alors

$$p = \sum_{k=0}^n a_k 2^k = 2 \sum_{k=1}^n a_k 2^{k-1} + a_0.$$

Ainsi, a_0 est le reste de la division euclidienne de p par 2 et, si $p \neq a_0$, $\underline{a_n \dots a_1}_2$ est le quotient de la division euclidienne de p par 2.

On peut donc écrire la fonction suivante.

```
def conv_b2(p):
    """Convertit l'entier p en base 2 (renvoie une chaine)"""
    x = p # On copie p
```

```
s = ""
i=0
while x > 1 :
    s = str(x%2) + s
    x = x // 2
    i=i+1
return str(x)+s

print('0=' + conv_b2(0) + ' et 1=' + conv_b2(1) + ' et 42=' + conv_b2(42))
```

0=0 et 1=1 et 42=101010

- **Invariant :** $p = x + s$, avec :
 - $s : s = a_{i-1} \dots a_1 a_0_2$
 - $x : x = \sum_{k=i}^n a_k 2^{k-i}$
- **Initialisation :** $i = 0$
 - $s : s$ est vide
 - $x : x = \sum_{k=i=0}^n a_k 2^{k-0} = p$
- On suppose l'hypothèse vrai au rang i , montrons qu'elle est vrai au rang $i + 1$:
- $x = \sum_{k=i}^n a_k 2^{k-i} = a_i + \sum_{k=i+1}^n a_k 2^{k-i} = a_i + 2 \cdot \sum_{k=i+1}^n a_k 2^{k-(i+1)}$
 - $x \% 2 \rightarrow a_i$
 - $x // 2 \rightarrow \sum_{k=i+1}^n a_k 2^{k-(i+1)}$
- **Terminaison :** à la sortie de la boucle $x \leq 1$ ce qui donne :

$$x = \sum_{k=i+1}^n a_k 2^{k-(i+1)} \leq 1$$

obtenue pour $i = n$ donc à la fin de la boucle $x = a_n$ et $s = a_{n-1} \dots a_1 a_0_2$, il faut donc bien ajouter a_n à s .

Somme de naturels

Dans un processeur n bits :

1. Un registre du processeur a n bits et peut représenter tout entier de $\llbracket 0, 2^n \rrbracket$.
2. Lorsqu'on effectue l'addition de deux registres r_1 et r_2 pour stocker le résultat dans r_3 , le registre fait n bits : s'il y a une retenue, elle est perdue.³
Exemple : après addition de 1111 0000 1111 0000₂ et 0011 0011 0011 0011₂ sur 16 bits, registre résultat : 0010 0100 0010 0011₂.

Troncature d'un entier p à ses n bits de poids faibles : valeur du reste de la division de p par 2^n (noté $p \% 2^n$).

Définitions :

1. Soit $p \in \mathbb{N}$. p représentable comme entier non signé sur n bits si $p \in \llbracket 0, 2^n \rrbracket$.
2. Représentation de p comme entier non signé sur n bits : suite des n chiffres de son écriture en binaire.
3. Abus de notation : on identifie $\llbracket 0, 2^n \rrbracket$ et les représentations sur n bits.
4. Soit $(p, q) \in \llbracket 0, 2^n \rrbracket^2$. somme (non signée) de p et q sur n bits : $(p + q) \% 2^n$, notée $p +_n q$ (notation non canonique).

Remarques pour $(p, q) \in \llbracket 0, 2^n \rrbracket^2$:

1. $p +_m q \equiv p + q \pmod{2^n}$.
2. $p +_n q = p + q$ si $p + q < 2^n$.
3. $p +_n q = p + q - 2^n$ si $p + q \geq 2^n$.

Entiers relatifs

Avec signe et valeur absolue

Première possibilité : $n - 1$ bits pour la valeur absolue et 1 bit pour le signe, par ex. :

- on représente -4 par 1000 0000 0000 0100₂ ;
- on représente 4 par 0000 0000 0000 0100₂.

Inconvénients :

1. Deux représentations pour zéro (1000 0000 0000 0000₂ et 0000 0000 0000 0000₂).

3. En fait une trace en est généralement gardée dans un autre registre du processeur.

- Plus compliqué à additionner que les entiers naturels.
Représentation quasiment jamais utilisée pour les nombres entiers d'un processeur.

Complément à deux

Idee géniale :

- L'addition d'entiers naturels sur le processeur n'est pas correcte mais l'est modulo 2^n ;
- pour tout $p \in \mathbb{Z}$, $p \% 2^n \in \llbracket 0, 2^n \llbracket$;
- donc $p \% 2^n$ représentable sur n bits ;
- l'addition de ces entiers relatifs sera correcte modulo 2^n .

Exemples :

- 5 est codé par $-5 \% 2^{16} = 65531 = \underline{1111\ 1111\ 1111\ 1011}_2$.
- 3 est codé par $3 \% 2^{16} = 3 = \underline{0000\ 0000\ 0000\ 0011}_2$.
- La somme obtenue par le processeur est

$$\underline{1111\ 1111\ 1111\ 1110}_2 = 65534 = 2^{16} - 2 = -2 \% 65536$$

- 4 est codé par $-4 \% 2^{16} = 65532 = \underline{1111\ 1111\ 1111\ 1100}_2$.
- 6 est codé par $6 \% 2^{16} = 6 = \underline{0000\ 0000\ 0000\ 0110}_2$.
- La somme obtenue par le processeur est

$$\underline{0000\ 0000\ 0000\ 0010}_2 = 2 = 2 \% 65536$$

Définitions :

- Soit $p \in \llbracket 0, 2^n \llbracket$. Complément à deux de p sur n bits : $(-p) \% 2^n$, noté $c_n(p)$ (non canonique).
- Soit $p \in \mathbb{Z}$. p est représentable comme entier signé sur n bits si $p \in \llbracket -2^{n-1}, 2^{n-1} \llbracket$.
- Soit $p \in \llbracket -2^{n-1}, 2^{n-1} \llbracket$. Représentation en complément à deux de p : $p \% 2^n$, notée $r_n(p)$ (non canonique).

Remarques :

- c_n involution⁴ de $\llbracket 0, 2^n \llbracket$.
- Soit $p \in \llbracket 0, 2^n \llbracket$. $c_n(p) = 2^n - p$ si $p \neq 0$, 0 si $p = 0$.
- r_n bijection de $\llbracket -2^{n-1}, 2^{n-1} \llbracket$ sur $\llbracket 0, 2^n \llbracket$.
- $\forall p \in \llbracket -2^{n-1} + 1, 2^{n-1} \llbracket$ $r_n(-p) = c_n(r_n(p))$.
- Pour tout $(p, q) \in \llbracket -2^{n-1}, 2^{n-1} \llbracket^2$ on a $r_n^{-1}(r_n(p) +_n r_n(q)) \equiv p + q [2^n]$.
- On a l'égalité si $p + q \in \llbracket -2^{n-1}, 2^{n-1} \llbracket$ (en particulier si p et q de signes différents).
- Le bit de poids fort de $r_n(p)$ vaut 1 si et seulement si $p < 0$.

Intérêt du complément à deux : Pour calculer une addition, on utilise exactement les mêmes circuits électroniques que pour des entiers non signés !

Calcul de la représentation en complément à deux

Définition Complément à un sur n bits de $\underline{a_{n-1} \dots a_{0_2}} : \underline{b_{n-1} \dots b_{0_2}}$ où $b_k = 1 - a_k$ pour $k \in \llbracket 0, n \llbracket$. On note $c'_n(p)$ cette valeur.

Proposition Pour tout $p \in \llbracket 0, 2^n \llbracket$,

$$p + c'_n(p) = \sum_{k \in \llbracket 0, n \llbracket} 2^k = 2^n - 1$$

Conséquence Pour tout p entier non signé sur n bits,

$$c_n(p) = c'_n(p) +_n 1$$

Conséquence (bis) Pour tout $p \in \llbracket -2^{n-1} + 1, 2^{n-1} \llbracket$

$$r_n(-p) = c'_n(r_n(p)) +_n 1$$

Exemple (sur 16 bits) :

- Représentation de 5 en tant qu'entier non signé ?
- Complément à un de 5 ?
- Complément à deux de 5 ?
- Représentation de -5 sur 16 bits ?
- Calcul de l'opposé de l'entier signé 1111 1111 1111 1000 ?
- Que vaut l'entier signé 1111 1111 1111 1000 ?

4. Bijection d'un ensemble sur lui-même qui est sa propre bijection réciproque.

Soustraction

Soit $(p, q) \in \llbracket 2^{n-1} - 1, 2^{n-1} \rrbracket$.

Définition Différence sur n bits de p et q : $(p - q) \% 2^n$, notée $p -_n q$ (non canonique).

Proposition $p -_n q = p +_n c_n(q)$.

1. Complément à deux facile à calculer.
2. Addition/Soustraction : utilisation du même circuit!

Octal et hexadécimal en informatique

1. Représenter des données par une succession de chiffres binaires est bien adapté à l'utilisation de l'électronique pour construire des ordinateurs.
2. C'est également bien adapté au calcul sur les entiers.

Exemple de représentation par du binaire :

- Une adresse IPv6 est une suite de 128 bits. Exemple d'adresse :

```
00100000000000010000011001111100
0000001011101000000000000100010
00000000000000000000000000000000
11000001000000000000011010001011
```

- Une adresse IPv4 est une suite de 32 bits. Exemple :

```
10000001101011110000111100001011
```

Ce n'est pas très pratique à manipuler...

Comment trouver une représentation plus simple à manipuler?

Deux possibilités :

1. Considérer ces suites de bits comme des entiers binaires et convertir en décimal (difficile à faire de tête)
2. Grouper ces suites de bits, par exemple par octet, remplacer chaque octet par sa représentation décimale.

Adresses IPv4 : 2^e solution. Sur l'adresse précédente : 129.175.15.11

2^e solution : pas pratique si la suite de bits représente un entier (difficile ensuite de calculer sur la représentation).

Autre solution :

1. Grouper les chiffres binaires par 4 (en partant de la droite)
2. Remplacer chaque groupement par le chiffre hexadécimal correspondant.

Avantages :

1. Facile à faire à la main et même de tête.
2. A du sens mathématiquement : le nombre hexadécimal obtenu a la même valeur que le nombre binaire de départ.

Solution prise pour les adresses IPv6.

Exemples :

- traduire en hexadécimal le nombre $11\ 0101\ 0010\ 1010\ 1110_2$
- traduire en binaire le nombre $90f5e56712_{16}$

Pour l'octal : même principe mais en groupant par 3.

1. Binaire, octal et hexadécimal sont très utilisés en informatique.
2. En Python, notations autorisées :

```
>>> 0b101010
42
>>> 0o52
42
>>> 0x2a
42
```

3. Écriture d'un entier n en décimal, binaire, octal ou hexadécimal : `str(n)`, `bin(n)`, `oct(n)`, `hex(n)`.

Danger, ancienne notation encore autorisée en Python 2 mais à ne plus utiliser :

```
>>> 052
42
```

En python 3 :

```
>>> 052
File "<stdin>", line 1
052
```

^
SyntaxError: invalid token

TD

Sources :

Savoirs et compétences :

- ☐ AA.C2 : Appréhender les limitations intrinsèques à la manipulation informatique des nombres
- ☐ AA.C3 : Initier un sens critique au sujet de la qualité et de la précision des résultats de calculs numériques sur ordinateur
- ☐ AA.S4 : Principe de la représentation des nombres entiers en mémoire
- ☐ AA.S5 : Principe de la représentation des nombres réels en mémoire

5 Applications

5.1 Dichotomie

En mathématiques, la méthode de la dichotomie à partir d'un segment $[a_0, b_0]$ donne deux suites infinies de réels (a_n) et (b_n) vérifiant $\forall n \in \mathbb{N}, a_n < b_n$.

Q 1 : Est-ce le cas en informatique?

Q 2 : Justifier la réponse et l'illustrer par un script.

Q 3 : Donner une estimation du plus petit nombre dénormalisé que l'on peut représenter sur 64 bits.

Q 4 : Conclure.